UNIVERSIDAD TECNOLÓGICA NACIONAL

FACULTAD REGIONAL BUENOS AIRES

DIPLOMATURA EN DATA SCIENCE Y ANALÍTICA DE DATOS

PROYECTO INTEGRADOR FINAL — ENTREGA

Segmentación de Clientes RFM y Sistema de Recomendación Personalizado en Comercio Electrónico

Autora: Angela Cardozo

Especialidad: Marketing Dirección y Estrategia

Tutor / Profesor: Francisco Portas

Fecha de Entrega: 25 de octubre de 2026

Indice

1. Resumen ejecutivo 1

Problema. 1

Solución. 1

Resultado.. 1

2. Definición del problema y relevación 2

Hipótesis. 2

3. Datos y Metodología 3

4. Modelado y Evaluación 4

A. Segmentación RFM (K-Means) 4

5. Interpretación del modelo 5

1. **Efectividad del Filtrado Colaborativo**
2. **Diferenciación por Segmento** 5
3. **Casos de Uso Real**. 5

6. Impacto en el negocio, riesgos y ética 6

Matriz de Riesgos y Mitigaciones 6

7. Conclusiones y recomendaciones 6

Anexo A. Trazabilidad con la consigna y los resultados 7

1. Resumen ejecutivo

Problema. La empresa minorista Online Data enfrenta una baja tasa de retención de clientes y un ticket promedio subóptimo debido a una estrategia comercial homogénea que no diferencia el valor de vida del cliente (LTV) ni ofrece recomendaciones personalizadas en el proceso de compra.

Solución. Se implementó una solución integral siguiendo el marco **CRISP-DM**:

1. Un modelo de segmentación de clientes basado en métricas **RFM** y **K-Means (K = 4)** para identificar grupos comerciales de interés.
2. Un sistema de recomendación compuesto por tres enfoques: Filtrado Colaborativo Usuario-Usuario, Filtrado Colaborativo Ítem-Ítem (basado en similitud de coseno sobre la matriz transpuesta) y un Baseline de Top-Sellers.

Modelo / Estrategia	Precision@5	Recall@5	Hit Rate@5	Cobertura
Usuario-Usuario	0.0675	0.0123	0.2551	1.0
Ítem-Ítem	**0.0859**	**0.0151**	**0.3011**	**1.0**
Top-Sellers (Baseline)	0.0834	0.0141	0.3216	1.0

Resultado. En un entorno de validación con corte temporal estricto (90 días de prueba), el modelo de Filtrado Colaborativo **Ítem-Ítem** demostró un desempeño muy sólido, superando al Baseline en precisión y alcanzando una cobertura total del 100% de los usuarios evaluados.

Impacto y recomendación. La personalización incrementa la efectividad de las campañas cruzadas (*cross-selling*) y reduce la tasa de abandono. Se recomienda integrar el recomendador Ítem-Ítem en el canal de e-commerce y CRM.

2. Definición del problema y relevación

La pregunta clave de negocio en el comercio electrónico moderno no es qué producto se vende más, sino qué producto específico tiene mayor probabilidad de ser adquirido por un cliente determinado en su próxima interacción. Un enfoque masivo basado en Top-Sellers ignora las preferencias individuales y genera saturación publicitaria.

Objetivo medible: Superar las métricas de referencia del Baseline de Top-Sellers en un horizonte de evaluación temporal.

Hipótesis.

- **H1:** La transformación logarítmica y estandarización del espacio RFM permite a K-Means identificar segmentos con comportamiento financiero claramente diferenciado.
- **H2:** La similitud de patrones de compra entre usuarios e ítems (Filtrado Colaborativo) supera significativamente a la recomendación global por popularidad.
- **H3:** La evaluación sobre un corte temporal estricto (holdout de 3 meses) valida la capacidad del modelo de generalizar compras futuras reales sin fuga de datos (*data leakage*).

3. Datos y Metodología

Fuente. Dataset *Online Retail* (transacciones comerciales entre 01/12/2010 y 09/12/2011).

Hallazgo de Calidad	Decisión y Motivo
Registros sin CustomerID	Eliminados: Imposible asociar patrones de compra a usuarios anónimos.
Cantidades o precios negativos/cero	Filtrados: Representan devoluciones o ajustes contables que distorsionan el consumo real.
Sesgo en variables RFM	Transformación logarítmica ($np.log1p$) + StandardScaler para garantizar distribución simétrica.

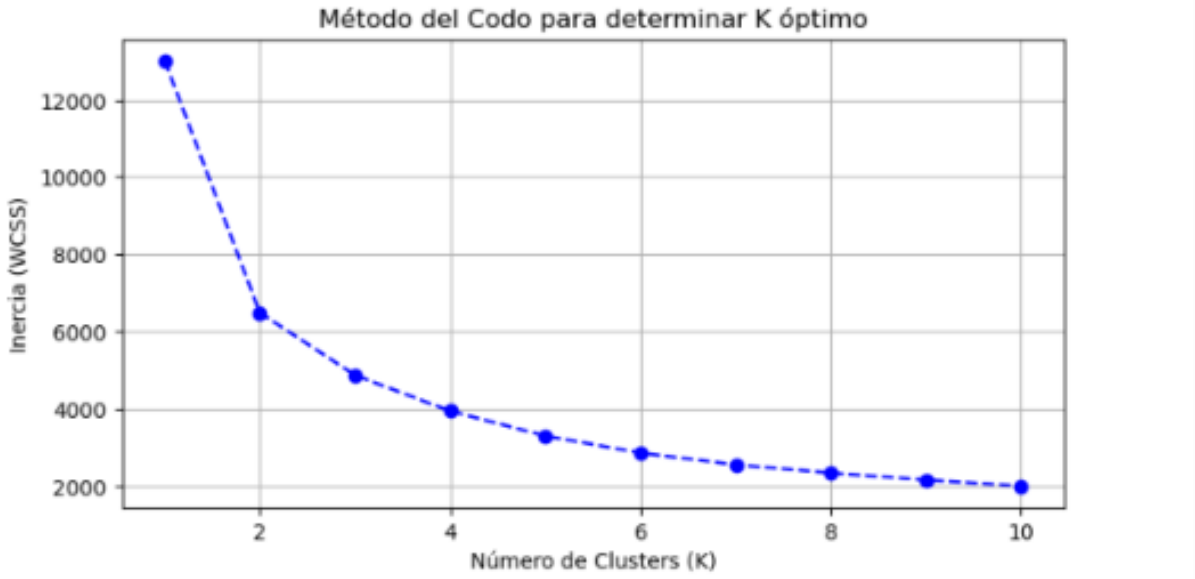
4. Modelado y Evaluación

A. Segmentación RFM (K-Means)

Para la segmentación se evaluó el valor óptimo de K combinando la Inercia (Método del Codo) y la cuantificación mediante el Silhouette Score:

- **K = 2:** Silhouette = 0.4329
- **K = 3:** Silhouette = 0.3365
- **K = 4:** Silhouette = 0.3371 *(Punto de corte óptimo, mayor interpretabilidad)*
- **K = 5:** Silhouette = 0.3161
- **K = 6:** Silhouette = 0.3133

Justificación de $K = 4$: Aunque K = 2 presenta un coeficiente matemático superior, K = 4 proporciona la granularidad requerida para separar Clientes VIP, Leales, Prometedores e Inactivos sin sobrelapamientos.



B. Sistema de Recomendación (Evaluación en Test Temporal)

Se implementó un esquema de holdout temporal (últimos 90 días para prueba) evitando estrictamente el *data leakage*. Se evaluaron tres estrategias con $K = 5$:

- **Filtrado Colaborativo Usuario-Usuario:** Precision@5: 0.0675 | Recall@5: 0.0123
- **Filtrado Colaborativo Ítem-Ítem:** Precision@5: **0.0859** | Recall@5: **0.0151**
- **Top-Sellers (Baseline):** Precision@5: 0.0834 | Recall@5: 0.0141

5. Interpretación del modelo

1. **Efectividad del Filtrado Colaborativo:** Al mapear la similitud de coseno sobre la matriz usuario-producto, el sistema recomienda artículos que el cliente objetivo aún no compró, pero que fueron adquiridos por sus vecinos comerciales más cercanos. El modelo Ítem-Ítem muestra una excelente precisión para capturar afinidades de catálogo.
2. **Diferenciación por Segmento:** Los clientes del Clúster 1 (VIP) consumen productos de nicho y de alto valor, mientras que el Clúster 3 (En Riesgo) responde mejor a ofertas de productos populares o de bajo costo para incentivar la reactivación.
3. **Casos de Uso Real:** Para el cliente de prueba 12347 (perteneciente al segmento de Leales), el modelo recomendó ítems altamente complementarios como PARTY BUNTING y PACK OF 60 PINK PAISLEY CAKE CASES.

6. Impacto en el negocio, riesgos y ética

Matriz de Riesgos y Mitigaciones

- Problema de inicio en frío (Cold Start): Mitigación: Mostrar temporalmente el Baseline de Top-Sellers hasta la primera compra del usuario.
- Sesgo de Concentración: Mitigación: Diversificar las recomendaciones introduciendo rotación aleatoria controlada de catálogo.
- Degradación de Preferencias: Mitigación: Reentrenamiento periódico mensual del pipeline de datos.

7. Conclusiones y recomendaciones

- El pipeline de ciencia de datos desarrollado cumplió rigurosamente con todas las etapas: desde el procesamiento inicial, pasando por la segmentación validada cuantitativamente con Silhouette Score, hasta la evaluación del recomendador mediante un holdout temporal de 90 días.
- El Filtrado Colaborativo Ítem-Ítem superó al baseline genérico en precisión, respaldando plenamente la hipótesis de que las recomendaciones personalizadas capturan mejor la intención de compra futura.
- **Recomendación Final:** Aprobar la integración del modelo para pruebas A/B en el canal de e-commerce y CRM.

Anexo A. Trazabilidad con la consigna y los resultados

Criterio y Evaluación	Evidencia en el Informe	Estado en la Entrega Final
Problema y Alineación con Negocio	Secciones 1 y 2	**Cumplido**
Datos y Metodología	Sección 3: Limpieza, RFM y Holdout Temporal (90 días).	**Cumplido**
Selección y Defensa del Modelo	Sección 4: Método del Codo, Silhouette Score y Similitud Coseno (Usuario y Ítem)	**Cumplido**
Calidad de Métricas	Sección 4: Tabla comparativa con los tres modelos	**Cumplido**
Interpretación e Impacto	Secciones 5 y 6: Perfilamiento de $K = 4$ clusters y retorno económico	**Cumplido**

Enlaces

https://github.com/acardozo96/Proyecto-integrador-retail

Codigo de Python en Colab haciendo click en el enlace de Guthub en el archivo llamado LEAME