**UNIVERSIDAD TECNOLÓGICA NACIONAL**

**FACULTAD REGIONAL BUENOS AIRES**

**DIPLOMATURA EN DATA SCIENCE Y ANALÍTICA DE DATOS**

**PROYECTO INTEGRADOR FINAL — ENTREGA**

# Segmentación de Clientes RFM y Sistema de Recomendación Personalizado en Comercio Electrónico

**Autora: Angela Cardozo**

**Especialidad: Marketing Dirección y Estrategia**

**Tutor / Profesor: Francisco Portas**

**Fecha de Entrega: 25 de octubre de 2026**

# Indice

**1. Resumen ejecutivo** ..... 1

Problema. ..... 1

Solución. ..... 1

Resultado. ..... 1

**2. Definición del problema y relevación** ..... 2

Hipótesis. ..... 3

**3. Datos y Metodología** ..... 3

Conclusiones del EDA ..... 3

Metodología de Validación (CRISP-DM) ..... 4

**4. Modelado y Evaluación** ..... 4

A. Segmentación RFM (K-Means) ..... 4

Centroides y Perfilamiento de Clústeres Obtenidos ($K = 4$) ..... 5

Sistema de Recomendación (Evaluación en Test Temporal) ..... 5

**5. Interpretación del modelo** ..... 6

1.Efectividad del Filtrado Colaborativo: ..... 6

2.Diferenciación por Segmento: ..... 6

3.Casos de Uso Real: ..... 6

**6. Impacto en el negocio, riesgos y ética** ..... 7

Estimación Económica Simulada ..... 7

Matriz de Riesgos y Mitigaciones ..... 7

**7. Conclusiones y recomendaciones** ..... 8

Anexo A. Trazabilidad con la consigna y la pre-entrega ..... 8

Anexo B. Reproducibilidad ..... 9

## 1. Resumen ejecutivo

**Problema.** La empresa minorista *Online Retail* enfrenta una baja tasa de retención de clientes y un ticket promedio subóptimo debido a una estrategia comercial homogénea que no diferencia el valor de vida del cliente (*LTV*) ni ofrece recomendaciones personalizadas en el proceso de compra.

**Solución.** Se implementó una solución integral siguiendo el marco **CRISP-DM**:

1. Un modelo de segmentación de clientes basado en métricas **RFM** y **K-Means (K = 4)** para identificar grupos comerciales de interés.
2. Un motor de recomendación basado en **Filtrado Colaborativo Usuario-Usuario (Similitud Coseno)** que sugiere productos a partir de los patrones de compra de usuarios afines.

| Indicador (Test Temporal 9m/3m) | Baseline (Top-Sellers) | Filtrado Colaborativo (K=5) | Mejora / Multiplicador |
|---|---|---|---|
| Precision@5 | 0,1074 | 0,2782 | **×2,59 (+140,4 %)** |
| Recall@5 | 0,0179 | 0,0792 | **×4,42 (+342,5 %)** |
| Ahorro / Valor Estimado por Campaña | - | USD 14.850 | - |

**Resultado.** En un entorno de validación con corte temporal estricto (9 meses de entrenamiento y 3 meses de prueba), el Filtrado Colaborativo alcanzó un **Precision@5 de 0,2782**, superando holgadamente el **0,1074** obtenido por el *Baseline de Top-Sellers*. El modelo demostró una capacidad superior para predecir compras futuras individuales en lugar de sugerir artículos genéricos.

**Impacto y recomendación.** La personalización incrementa la efectividad de las campañas cruzadas (*cross-selling*) y reduce la tasa de abandono. Se recomienda integrar los

segmentos RFM al CRM de la empresa para automatizar campañas por correo y ejecutar un **piloto A/B en producción** para medir la conversión directa antes del despliegue masivo.

## 2. Definición del problema y relevación

La pregunta clave de negocio en el comercio electrónico moderno no es qué producto se vende más, sino **qué producto específico tiene mayor probabilidad de ser adquirido por un cliente determinado en su próxima interacción**. Un enfoque masivo basado en Top-Sellers ignora las preferencias individuales y genera saturación publicitaria.

**Objetivo medible (fijado ex ante):** Superar en al menos un 100 % la precisión del *Baseline de* Top-Sellers en un horizonte de evaluación temporal, alcanzando un $Precision@5 \geq 0{,}20$.
**Benchmark:** El ordenamiento por popularidad global logra $Precision@5 = 0{,}1074$.

| Situación | Lectura estadística | Costo de negocio |
|---|---|---|
| Recomendación no comprada | Falso positivo | Desgaste de la atención del cliente, menor tasa de clics (CTR). |
| Producto afín no recomendado | Falso negativo | Oportunidad perdida de venta cruzada (cross-selling) y menor ticket. |
| Recomendar solo populares | Baseline simplista | Cero diferenciación; imposibilidad de activar productos de "larga cola" (long-tail). |

## Hipótesis.

- **H1:** La transformación logarítmica y estandarización del espacio RFM permite a K-Means identificar segmentos con comportamiento financiero claramente diferenciado.
- **H2:** La similitud de patrones de compra entre usuarios (Filtrado Colaborativo) supera significativamente a la recomendación global por popularidad.
- **H3:** La evaluación sobre un corte temporal estricto (holdout de 3 meses) valida la capacidad del modelo de generalizar compras futuras reales.

## 3. Datos y Metodología

**Fuente. Dataset *Online Retail* (transacciones comerciales entre 01/12/2010 y 09/12/2011).**

| Hallazgo de Calidad | Decisión y Motivo |
|---|---|
| **Registros sin CustomerID** | Eliminados: Imposible asociar patrones de compra a usuarios anónimos. |
| **Cantidades o precios negativos/cero** | Filtrados: Representan devoluciones o ajustes contables que distorsionan el consumo real. |
| **Duplicados exactos** | Eliminados para evitar sobreponderar transacciones repetidas. |
| **Sesgo en variables RFM** | Transformación logarítmica np.log1p() + StandardScaler() para garantizar distribución simétrica. |

## Conclusiones del EDA

1. La distribución del gasto y frecuencia presenta una fuerte asimetría positiva (*long-tail*).
2. Un porcentaje reducido de clientes representa la mayor parte del margen operativo (principio de Pareto).
3. La estacionalidad mensual muestra un incremento crítico de compras en el último trimestre.

## Metodología de Validación (CRISP-DM)

Se aplicó un diseño de **Holdout Temporal Estricto**: los primeros 9 meses de datos formaron el conjunto de entrenamiento (train_set) y los últimos 3 meses constituyeron el conjunto de evaluación (test_set), evitando el sesgo de fuga de información hacia el futuro.

## 4. Modelado y Evaluación

### A. Segmentación RFM (K-Means)

Para la segmentación se evaluó el valor óptimo de K combinando la Inercia (Método del Codo) y la cuantificación mediante el Silhouette Score:

| Cantidad de Clusters (K) | Silhouette Score (Cohesión / Separación) |
|---|---|
| $K = 2$ | 0,4329 |
| $K = 3$ | 0,3365 |
| $K = 4$ | 0,3371 (Elegido por interpretabilidad de negocio) |
| $K = 5$ | 0,3161 |
| $K = 6$ | 0,3133 |

Justificación de $K = 4$: Aunque $K = 2$ presenta un coeficiente matemático superior, $K = 4$ proporciona la granularidad requerida para separar Clientes VIP, Leales, Prometedores e Inactivos sin sobre-segmentar.

## Centroides y Perfilamiento de Clústeres Obtenidos ($K = 4$)

| Cluster ID | Perfil Comercial | Recency Media (Días) | Frequency Media (Facturas) |
|---|---|---|---|
| 1 | VIP / Alto Valor | 12,1 | **13,7** |
| 2 | Leales / Frecuentes | **71,1** | 4,1 |
| 0 | Nuevos / Prometedores | **18,1** | **2,1** |
| 3 | En Riesgo / Inactivos | 182,5 | 1,3 |

## Sistema de Recomendación (Evaluación en Test Temporal)

| Modelo / Estrategia | Precision@5 | Recall@5 | Descripción / Desempeño |
|---|---|---|---|
| **Ranking Aleatorio** | 0,0112 | 0,0021 | Asignación al azar. |
| **Baseline Top-Sellers** | 0,1074 | 0,0179 | Sugiere únicamente los 5 productos más vendidos globales |
| **Filtrado Colaborativo (U-U)** | **0,2782** | **0,0792** | Modelo Seleccionado: Multiplica por 2,59x la precisión del baseline |

## 5. Interpretación del modelo

1. **Efectividad del Filtrado Colaborativo:** Al mapear la similitud coseno sobre la matriz Usuario-Producto binarizada, el sistema recomienda artículos que el cliente objetivo aún no compró, pero que fueron adquiridos por sus "vecinos comerciales" más cercanos.
2. **Diferenciación por Segmento:** Los clientes del **Clúster 1 (VIP)** consumen productos de nicho y de alto valor, mientras que el **Clúster 3 (En Riesgo)** responde mejor a ofertas de productos populares o de bajo costo para incentivar la reactivación.
3. **Casos de Uso Real:** Para el cliente de prueba 12347 (perteneciente al segmento de Leales), el modelo recomendó ítems altamente complementarios como PARTY BUNTING y PACK OF 60 PINK PAISLEY CAKE CASES.

## 6. Impacto en el negocio, riesgos y ética

### Estimación Económica Simulada

| Escenario | Estrategia | Precision@5 | Conversiones Estimadas |
|---|---|---|---|
| **Sin Personalización** | Recomendación Genérica | 10,7 % | Básicas |
| **Con Recomendador** | Filtrado Colaborativo | **27,8 %** | **Altas (+159 %)** |

### Matriz de Riesgos y Mitigaciones

| Riesgo | Mitigación |
|---|---|
| **Problema de Inicio en Frío (*Cold Start*)** | Para usuarios nuevos sin historial, mostrar temporalmente el *Baseline Top-Sellers* hasta su primera compra. |
| **Sesgo de Concentración** | Para usuarios nuevos sin historial, mostrar temporalmente el *Baseline Top-Sellers* hasta su primera compra. |
| **Degradación de Preferencias** | Reentrenar periódicamente la matriz de similitud de forma mensual. |

## 7. Conclusiones y recomendaciones

- El pipeline de ciencia de datos desarrollado cumplió rigurosamente con todas las etapas: desde el procesamiento inicial, pasando por la segmentación validada cuantitativamente con **Silhouette Score**, hasta la evaluación del recomendador mediante un **Holdout Temporal (9m/3m)**.
- El **Filtrado Colaborativo Usuario-Usuario** superó de manera contundente al baseline genérico ($Precision@5 = 0{,}2782$ vs $0{,}1074$), respaldando plenamente la hipótesis de que las recomendaciones personalizadas capturan mejor la intención de compra futura.
- **Recomendación Final:** Aprobar la integración del modelo para pruebas A/B en el canal de e-commerce y CRM.

### Anexo A. Trazabilidad con la consigna y la pre-entrega

| Criterio y Evaluación | Evidencia en el Informe | Estado en la Entrega Final |
|---|---|---|
| **Problema y Alineación con Negocio** | Secciones 1 y 2: Estrategia de retención y cross-selling. | **Cumplido** |
| **Datos y Metodología** | Sección 3: Limpieza, RFM y Holdout Temporal (9m/3m). | **Cumplido** |
| **Selección y Defensa del Modelo** | Sección 4: Método del Codo, **Silhouette Score** y Similitud Coseno. | **Cumplido** |
| **Calidad de Métricas** | Sección 4: **Precision@5 (0,2782)** y **Recall@5 (0,0792)** vs **Baseline (0,1074)**. | **Cumplido** |
| **Interpretación e Impacto** | Secciones 5 y 6: Perfilamiento de $K = 4$ clusters y retorno económico | **Cumplido** |

## Anexo B. Reproducibilidad

- Proyecto_Integrador_EntregaFinal.ipynb— Notebook principal con todo el código de análisis, EDA, modelado y métricas ejecutado en **Google Colab** .
- informe_final.pdf— Informe escrito formal del proyecto (Formato institucional UTN).
- presentacion.pdf— Presentación visual en formato de diapositivas para la defensa oral.
- Haga clic directamente sobre el archivo .ipynben este repositorio de GitHub y seleccione la opción de abrir con Google Colab.
- El notebook descarga de forma automatizada el dataset oficial y aplica el pipeline de preprocesamiento.
- Se han fijado semillas aleatorias ( random_state = 42) en todos los algoritmos de Machine Learning para garantizar la **reproducibilidad exacta** de los resultados y métricas presentadas en el informe.
- Ejecutá las celdas de manera secuencial ( Runtime -> Run all/ Ejecutar todas).

## *Enlaces*

https://github.com/acardozo96/Proyecto-integrador-retail

Codigo de Python en Colab haciendo click en el enlace de Guthub en el archivo llamado LEAME