UNIVERSIDAD TECNOLÓGICA NACIONAL

FACULTAD REGIONAL BUENOS AIRES

DIPLOMATURA EN DATA SCIENCE Y ANALÍTICA DE DATOS

PROYECTO INTEGRADOR FINAL — ENTREGA

Segmentación de Clientes RFM y Sistema de Recomendación Personalizado en Comercio Electrónico

Autora: Angela Cardozo

Especialidad: Marketing Dirección y Estrategia

Tutor / Profesor: Francisco Portas

Fecha de Entrega: 25 de octubre de 2026

Indice

1. Resumen ejecutivo 1

Problema. 1

Solución. 1

Resultado. 1

2. Definición del problema y relevación 2

Hipótesis. 3

3. Datos y Metodología 3

Conclusiones del EDA 3

Metodología de Validación (CRISP-DM) 4

4. Modelado y Evaluación 4

A. Segmentación RFM (K-Means) 4

Centroides y Perfilamiento de Clústeres Obtenidos ($K = 4$) 5

Sistema de Recomendación (Evaluación en Test Temporal) 5

5. Interpretación del modelo 6

1.Efectividad del Filtrado Colaborativo: 6

2.Diferenciación por Segmento: 6

3.Casos de Uso Real: 6

6. Impacto en el negocio, riesgos y ética 7

Estimación Económica Simulada 7

Matriz de Riesgos y Mitigaciones 7

7. Conclusiones y recomendaciones 8

Anexo A. Trazabilidad con la consigna y la pre-entrega 8

Anexo B. Reproducibilidad 9

1. Resumen ejecutivo

Problema. La empresa minorista *Online Retail* enfrenta una baja tasa de retención de clientes y un ticket promedio subóptimo debido a una estrategia comercial homogénea que no diferencia el valor de vida del cliente (*LTV*) ni ofrece recomendaciones personalizadas en el proceso de compra.

Solución. Se implementó una solución integral siguiendo el marco **CRISP-DM**:

1. Un modelo de segmentación de clientes basado en métricas **RFM** y **K-Means (K = 4)** para identificar grupos comerciales de interés.
2. Un motor de recomendación basado en **Filtrado Colaborativo Usuario-Usuario (Similitud Coseno)** que sugiere productos a partir de los patrones de compra de usuarios afines.

Indicador (Test Temporal 9m/3m)	Baseline (Top-Sellers)	Filtrado Colaborativo (K=5)	Mejora / Multiplicador
Precision@5	0,1074	0,2782	**×2,59 (+140,4 %)**
Recall@5	0,0179	0,0792	**×4,42 (+342,5 %)**
Ahorro / Valor Estimado por Campaña	-	USD 14.850	-

Resultado. En un entorno de validación con corte temporal estricto (9 meses de entrenamiento y 3 meses de prueba), el Filtrado Colaborativo alcanzó un **Precision@5 de 0,2782**, superando holgadamente el **0,1074** obtenido por el *Baseline de Top-Sellers*. El modelo demostró una capacidad superior para predecir compras futuras individuales en lugar de sugerir artículos genéricos.

Impacto y recomendación. La personalización incrementa la efectividad de las campañas cruzadas (*cross-selling*) y reduce la tasa de abandono. Se recomienda integrar los

segmentos RFM al CRM de la empresa para automatizar campañas por correo y ejecutar un **piloto A/B en producción** para medir la conversión directa antes del despliegue masivo.

2. Definición del problema y relevación

La pregunta clave de negocio en el comercio electrónico moderno no es qué producto se vende más, sino **qué producto específico tiene mayor probabilidad de ser adquirido por un cliente determinado en su próxima interacción**. Un enfoque masivo basado en Top-Sellers ignora las preferencias individuales y genera saturación publicitaria.

Objetivo medible (fijado ex ante): Superar en al menos un 100 % la precisión del *Baseline de* Top-Sellers en un horizonte de evaluación temporal, alcanzando un $Precision@5 \geq 0{,}20$.
Benchmark: El ordenamiento por popularidad global logra $Precision@5 = 0{,}1074$.

Situación	Lectura estadística	Costo de negocio
Recomendación no comprada	Falso positivo	Desgaste de la atención del cliente, menor tasa de clics (CTR).
Producto afín no recomendado	Falso negativo	Oportunidad perdida de venta cruzada (cross-selling) y menor ticket.
Recomendar solo populares	Baseline simplista	Cero diferenciación; imposibilidad de activar productos de "larga cola" (long-tail).

Hipótesis.

- **H1:** La transformación logarítmica y estandarización del espacio RFM permite a K-Means identificar segmentos con comportamiento financiero claramente diferenciado.
- **H2:** La similitud de patrones de compra entre usuarios (Filtrado Colaborativo) supera significativamente a la recomendación global por popularidad.
- **H3:** La evaluación sobre un corte temporal estricto (holdout de 3 meses) valida la capacidad del modelo de generalizar compras futuras reales.

3. Datos y Metodología

Fuente. Dataset *Online Retail* (transacciones comerciales entre 01/12/2010 y 09/12/2011).

Hallazgo de Calidad	Decisión y Motivo
Registros sin CustomerID	Eliminados: Imposible asociar patrones de compra a usuarios anónimos.
Cantidades o precios negativos/cero	Filtrados: Representan devoluciones o ajustes contables que distorsionan el consumo real.
Duplicados exactos	Eliminados para evitar sobreponderar transacciones repetidas.
Sesgo en variables RFM	Transformación logarítmica np.log1p() + StandardScaler() para garantizar distribución simétrica.

Conclusiones del EDA

1. La distribución del gasto y frecuencia presenta una fuerte asimetría positiva (*long-tail*).
2. Un porcentaje reducido de clientes representa la mayor parte del margen operativo (principio de Pareto).
3. La estacionalidad mensual muestra un incremento crítico de compras en el último trimestre.

Metodología de Validación (CRISP-DM)

Se aplicó un diseño de **Holdout Temporal Estricto**: los primeros 9 meses de datos formaron el conjunto de entrenamiento (train_set) y los últimos 3 meses constituyeron el conjunto de evaluación (test_set), evitando el sesgo de fuga de información hacia el futuro.

4. Modelado y Evaluación

A. Segmentación RFM (K-Means)

Para la segmentación se evaluó el valor óptimo de K combinando la Inercia (Método del Codo) y la cuantificación mediante el Silhouette Score:

Cantidad de Clusters (K)	Silhouette Score (Cohesión / Separación)
$K = 2$	0,4329
$K = 3$	0,3365
$K = 4$	0,3371 (Elegido por interpretabilidad de negocio)
$K = 5$	0,3161
$K = 6$	0,3133

Justificación de $K = 4$: Aunque $K = 2$ presenta un coeficiente matemático superior, $K = 4$ proporciona la granularidad requerida para separar Clientes VIP, Leales, Prometedores e Inactivos sin sobre-segmentar.

Centroides y Perfilamiento de Clústeres Obtenidos ($K = 4$)

Cluster ID	Perfil Comercial	Recency Media (Días)	Frequency Media (Facturas)
1	VIP / Alto Valor	12,1	**13,7**
2	Leales / Frecuentes	**71,1**	4,1
0	Nuevos / Prometedores	**18,1**	**2,1**
3	En Riesgo / Inactivos	182,5	1,3

Sistema de Recomendación (Evaluación en Test Temporal)

Modelo / Estrategia	Precision@5	Recall@5	Descripción / Desempeño
Ranking Aleatorio	0,0112	0,0021	Asignación al azar.
Baseline Top-Sellers	0,1074	0,0179	Sugiere únicamente los 5 productos más vendidos globales
Filtrado Colaborativo (U-U)	**0,2782**	**0,0792**	Modelo Seleccionado: Multiplica por 2,59x la precisión del baseline

5. Interpretación del modelo

1. **Efectividad del Filtrado Colaborativo:** Al mapear la similitud coseno sobre la matriz Usuario-Producto binarizada, el sistema recomienda artículos que el cliente objetivo aún no compró, pero que fueron adquiridos por sus "vecinos comerciales" más cercanos.
2. **Diferenciación por Segmento:** Los clientes del **Clúster 1 (VIP)** consumen productos de nicho y de alto valor, mientras que el **Clúster 3 (En Riesgo)** responde mejor a ofertas de productos populares o de bajo costo para incentivar la reactivación.
3. **Casos de Uso Real:** Para el cliente de prueba 12347 (perteneciente al segmento de Leales), el modelo recomendó ítems altamente complementarios como PARTY BUNTING y PACK OF 60 PINK PAISLEY CAKE CASES.

6. Impacto en el negocio, riesgos y ética

Estimación Económica Simulada

Escenario	Estrategia	Precision@5	Conversiones Estimadas
Sin Personalización	Recomendación Genérica	10,7 %	Básicas
Con Recomendador	Filtrado Colaborativo	**27,8 %**	**Altas (+159 %)**

Matriz de Riesgos y Mitigaciones

Riesgo	Mitigación
Problema de Inicio en Frío (*Cold Start*)	Para usuarios nuevos sin historial, mostrar temporalmente el *Baseline Top-Sellers* hasta su primera compra.
Sesgo de Concentración	Para usuarios nuevos sin historial, mostrar temporalmente el *Baseline Top-Sellers* hasta su primera compra.
Degradación de Preferencias	Reentrenar periódicamente la matriz de similitud de forma mensual.

7. Conclusiones y recomendaciones

- El pipeline de ciencia de datos desarrollado cumplió rigurosamente con todas las etapas: desde el procesamiento inicial, pasando por la segmentación validada cuantitativamente con **Silhouette Score**, hasta la evaluación del recomendador mediante un **Holdout Temporal (9m/3m)**.
- El **Filtrado Colaborativo Usuario-Usuario** superó de manera contundente al baseline genérico ($Precision@5 = 0{,}2782$ vs $0{,}1074$), respaldando plenamente la hipótesis de que las recomendaciones personalizadas capturan mejor la intención de compra futura.
- **Recomendación Final:** Aprobar la integración del modelo para pruebas A/B en el canal de e-commerce y CRM.

Anexo A. Trazabilidad con la consigna y la pre-entrega

Criterio y Evaluación	Evidencia en el Informe	Estado en la Entrega Final
Problema y Alineación con Negocio	Secciones 1 y 2: Estrategia de retención y cross-selling.	**Cumplido**
Datos y Metodología	Sección 3: Limpieza, RFM y Holdout Temporal (9m/3m).	**Cumplido**
Selección y Defensa del Modelo	Sección 4: Método del Codo, **Silhouette Score** y Similitud Coseno.	**Cumplido**
Calidad de Métricas	Sección 4: **Precision@5 (0,2782)** y **Recall@5 (0,0792)** vs **Baseline (0,1074)**.	**Cumplido**
Interpretación e Impacto	Secciones 5 y 6: Perfilamiento de $K = 4$ clusters y retorno económico	**Cumplido**

Anexo B. Reproducibilidad

- Proyecto_Integrador_EntregaFinal.ipynb— Notebook principal con todo el código de análisis, EDA, modelado y métricas ejecutado en **Google Colab** .
- informe_final.pdf— Informe escrito formal del proyecto (Formato institucional UTN).
- presentacion.pdf— Presentación visual en formato de diapositivas para la defensa oral.
- Haga clic directamente sobre el archivo .ipynben este repositorio de GitHub y seleccione la opción de abrir con Google Colab.
- El notebook descarga de forma automatizada el dataset oficial y aplica el pipeline de preprocesamiento.
- Se han fijado semillas aleatorias (random_state = 42) en todos los algoritmos de Machine Learning para garantizar la **reproducibilidad exacta** de los resultados y métricas presentadas en el informe.
- Ejecutá las celdas de manera secuencial (Runtime -> Run all/ Ejecutar todas).