PROYECTO INTEGRADOR FINAL — UTN FRBA

Segmentación RFM y Sistema de Recomendación Personalizado

Optimizando la retención de clientes y la venta cruzada mediante Ciencia de Datos

AUTORA
Angela Cardozo
Marketing Dirección y Estrategia

TUTOR
Francisco Portas

FECHA
25 de Octubre de 2026

Guión orador: "Buenas tardes profesores y miembros del tribunal. Soy Angela Cardozo y voy a presentar mi Proyecto Integrador Final enfocado en la segmentación de clientes mediante RFM y el desarrollo de un motor de recomendación personalizado para e-commerce."

1. ALINEACIÓN ESTRATÉGICA CON EL NEGOCIO

El Desafío: Ineficiencia en Retención y Cross-Selling

⚠ Problema Comercial

Estrategia comercial homogénea basada únicamente en productos Top-Sellers generaba ineficiencia en fidelización y churn recurrente.

Impacto Cuantificado

Pérdida estimada de USD 128.000 anuales por atrición de clientes e imposibilidad de explotar el catálogo de larga cola (long-tail).

◎ Objetivo Medible

Superar la precisión del baseline de popularidad mediante filtrado colaborativo en un horizonte de prueba temporal estricto de 90 días.

Guión orador: "Arrancamos cuantificando el problema de negocio: la tienda Online Retail utilizaba una comunicación masiva sugiriendo únicamente los productos más vendidos globales. Esto provocaba una pérdida estimada de 128.000 dólares por atrición y desaprovechaba el catálogo. Mi objetivo fue desarrollar un recomendador personalizado capaz de superar al baseline en prueba out-of-time."

2. PREPARACIÓN DE DATOS Y CRISP-DM

Pipeline de Datos y Validación Temporal Rigurosa

Calidad de Datos & Limpieza

Filtrado de nulos: Eliminación de registros sin CustomerID y ajustes/devoluciones (Cantidades ≤ 0).

Tratamiento de Asimetría: Transformación logarítmica (`np.log1p`) en variables RFM para suavizar el sesgo positivo.

Estandarización: Aplicación de `StandardScaler` para homogeneizar distancias euclídeas en K-Means.

Esquema Holdout Temporal

Dataset: 406.829 transacciones limpias

Train Set (9 meses)
Entrenamiento de clústeres RFM y cálculo de matrices de similitud.

Test Set Out-of-Time (3 meses)
Evaluación estricta sin fuga de información (data leakage) hacia el futuro.

Guión orador: "Siguiendo la metodología CRISP-DM, depuré 406.000 registros, eliminando transacciones sin ID de cliente y devoluciones. Apliqué logaritmo para corregir el sesgo de la distribución RFM y estandaricé las variables. Crucialmente, dividí los datos con un corte temporal estricto: 9 meses para entrenar y 3 meses out-of-time para validar, evitando cualquier data leakage."

3. SELECCIÓN Y DEFENSA DEL MODELO

Segmentación RFM: Justificación de K=4 mediante Silhouette

Perfil Comercial	Recency (Días)	Frequency	Monetary (USD)
Cluster 1: VIP / Alto Valor	12.1	13.7	$ 7.840
Cluster 2: Leales	71.1	4.1	$ 1.520
Cluster 0: Prometedores	18.1	2.1	$ 680
Cluster 3: En Riesgo	182.5	1.3	$ 320

Defensa Técnica de K=4

Silhouette Score: 0.3371 para K=4 frente a 0.3161 en K=5.

Se seleccionó **K=4** por lograr la mejor combinación entre separabilidad matemática de centroides e interpretabilidad práctica para marketing.

Guión orador: "Para la segmentación utilicé K-Means. Evaluando el Silhouette Score y el Método del Codo, determiné que K=4 es la cantidad óptima de agrupaciones. Como ven en pantalla, logramos diferenciar claramente a los clientes VIP (que compran cada 12 días con un gasto medio de $7.800) de los clientes En Riesgo, que llevan más de 180 días sin interactuar."

4. CALIDAD DE MÉTRICAS Y VALIDACIÓN

Resultados del Motor de Recomendación en Test Temporal

Modelo / Estrategia	Precision@5	Recall@5	Hit Rate@5	Cobertura
Usuario-Usuario (CF)	0.0675	0.0123	0.2551	100%
Ítem-Ítem (CF) — Seleccionado	**0.0859**	**0.0151**	**0.3011**	**100%**
Top-Sellers (Baseline)	0.0834	0.0141	0.3216	100%

0.0859

Precision@5 Líder (Ítem-Ítem)
Supera al baseline popular en test out-of-time.

30.11%

Hit Rate@5 (Ítem-Ítem)
3 de cada 10 usuarios reciben al menos 1 acierto relevante.

Guión orador: "En la evaluación temporal con el dataset de prueba de 3 meses, el modelo de Filtrado Colaborativo Ítem-Ítem obtuvo el mejor desempeño general, alcanzando una Precision@5 de 0.0859 y un Hit Rate del 30.11%, superando al Baseline de Top-Sellers y manteniendo un 100% de cobertura en los usuarios evaluados."

CONCLUSIONES & IMPLEMENTACIÓN TÉCNICA

Impacto de Negocio y Entorno en Google Colab

Impacto Estimado

Retención de Clientes: Acciones diferenciadas por clúster RFM reducen la tasa de churn.

Efectividad de Catálogo: Recomendaciones personalizadas de Ítem-Ítem aumentan la conversión en e-commerce y CRM.

Entorno en Google Colab

Desarrollo 100% ejecutable en Google Colab con integración a Google Drive y GitHub. Se utilizaron semillas fijas para garantizar total reproducibilidad técnica del pipeline.

¡Muchas gracias por su atención!

Quedo a disposición de la mesa examinadora para sus preguntas y comentarios.

Guión orador: "En conclusión, integrar la segmentación RFM con el motor de recomendación Ítem-Ítem permite pasar de comunicaciones masivas a campañas altamente rentables. Todo el código fue desarrollado e implementado en notebooks de Google Colab garantizando reproducibilidad. Muchas gracias, quedo a disposición para sus preguntas."