PROYECTO INTEGRADOR FINAL — UTN FRBA

Segmentación RFM y Sistema de Recomendación Personalizado

Optimizando la retención de clientes y la venta cruzada mediante Ciencia de Datos

Autora: Angela Cardozo | **Especialidad:** Marketing Dirección y Estrategia
Tutor: Francisco Portas | **Fecha:** 25 de Octubre de 2026

🗣️ **Guión orador:** "Buenas tardes profesores y miembros del tribunal. Soy Angela Cardozo y voy a presentar mi Proyecto Integrador Final enfocado en la segmentación de clientes mediante RFM y el desarrollo de un motor de recomendación personalizado para e-commerce."

1. ALINEACIÓN ESTRATÉGICA CON EL NEGOCIO (20%)

El Desafío: Ineficiencia en la Retención y Cross-Selling

⚠️ Problema

Estrategia comercial homogénea basada únicamente en productos Top-Sellers. Ineficiencia en acciones de fidelización y churn recurrente.

💰 Impacto Cuantificado

Pérdida estimada de USD 128.000 anuales por atrición de clientes e imposibilidad de explotar el catálogo de larga cola (long-tail).

🎯 Objetivo Medible

Superar en un +100% la precisión del baseline popular alcanzando un Precision@5 ≥ 0.20 en prueba out-of-time.

🗣️ **Guión orador:** "Arrancamos cuantificando el problema de negocio: la tienda Online Retail utilizaba una comunicación masiva sugiriendo únicamente los productos más vendidos globales. Esto provocaba una pérdida de casi 128.000 dólares por atrición y desaprovechaba el 80% del catálogo. Mi objetivo concreto fue superar en más de un 100% la precisión de este método genérico."

2. PREPARACIÓN DE DATOS Y CRISP-DM (20%)

Pipeline de Datos y Validación Temporal Rigurosa

Calidad de Datos & Limpieza

- **Filtrado:** Eliminación de 25% de registros sin CustomerID y ajustes contables (Cantidades ≤ 0).
- **Tratamiento de Asimetría:** Transformación logarítmica en variables RFM.
- **Estandarización:** Aplicación de para normalizar distancias euclídeas.

Esquema Holdout Temporal

📅 **Dataset: 406.829 transacciones**

- **Train Set (9 meses):** Entrenamiento del modelo y cálculo de vectores RFM.
- **Test Set Out-of-Time (3 meses):** Evaluación estricta sin fuga de información hacia el futuro.

🗣️ **Guión orador:** "Siguiendo la metodología CRISP-DM, depuré 406.000 registros, eliminando transacciones sin ID de cliente y devoluciones. Apliqué logaritmo para corregir el sesgo positivo extremo de la distribución RFM y estandaricé las variables. Crucialmente, dividí los datos con un corte temporal estricto: 9 meses para entrenar y 3 meses out-of-time para validar, evitando cualquier data leakage."

3. SELECCIÓN Y DEFENSA DEL MODELO (15%)

Segmentación RFM: Justificación de K = 4 mediante Silhouette

Cluster ID	Perfil Comercial	Recency (Días)	Frequency (Facturas)	Monetary (USD)
1	VIP / Alto Valor	12,1	13,7	$ 7.840
2	Leales / Recurrentes	71,1	4,1	$ 1.520
0	Prometedores	18,1	2,1	$ 680
3	En Riesgo / Inactivos	182,5	1,3	$ 320

📈 Defensa Técnica de K=4

Silhouette Score: 0,3371 para K=4 frente a 0,3161 en K=5.

Se seleccionó K=4 por lograr la mejor combinación entre separabilidad matemática de centroides e interpretabilidad para las estrategias de marketing del negocio.

🗣️ **Guión orador:** "Para la segmentación utilicé K-Means. Evaluando el Silhouette Score y el Método del Codo, determiné que K=4 es la cantidad óptima de agrupaciones. Como ven en pantalla, logramos diferenciar claramente a los clientes VIP (que compran cada 12 días con un gasto medio de $7.800) de los clientes En Riesgo, que llevan más de 180 días sin interactuar."

4. CALIDAD DE MÉTRICAS Y VALIDACIÓN (15%)

Resultados del Motor de Recomendación vs. Baseline

Modelo / Estrategia	Precision@5	Recall@5	MRR@5	Desempeño Observado
Ranking Aleatorio	0,0112	0,0021	0,0150	Asignación al azar. Pésimo.
Baseline Top-Sellers	0,1074	0,0179	0,1420	Recomendación popular genérica.
Filtrado Colaborativo (U-U)	**0,2782**	**0,0792**	**0,3150**	**Modelo Seleccionado (K=5 vecinos)**

+140.4%

Incremento en Precision@5 frente al Baseline

+342.5%

Incremento en Recall@5 frente al Baseline

🗣️ **Guión orador:** "En cuanto a las métricas del motor de recomendación evaluadas en el test out-of-time, el Filtrado Colaborativo Usuario-Usuario logró una Precision@5 del 27.82%, superando con creces la meta propuesta y multiplicando por 2.59 veces al baseline popular. El MRR alcanzó 0.3150, confirmando que los productos relevantes aparecen en las primeras posiciones sugeridas."

CONCLUSIONES & IMPLEMENTACIÓN TÉCNICA

Impacto de Negocio y Entorno en Google Colab

Impacto Estimado

- Conversión simulada: Incremental del **+159%** en ventas cruzadas.
- Retorno esperado: Retención directa y ganancia estimada de **USD 14.850** por campaña segmentada.

Entorno en Google Colab

- Desarrollo 100% ejecutable en **Google Colab** con Google Drive.
- Semilla fija para total reproducibilidad técnica. `random_state=42`

¡Muchas gracias por su atención!

Quedo a disposición de la mesa examinadora para sus preguntas y comentarios.

🗣️ **Guión orador:** "En conclusión, integrar la segmentación RFM con el motor de recomendación permite pasar de comunicaciones masivas a campañas altamente rentables. Todo el código fue desarrollado e implementado en notebooks de Google Colab garantizando total reproducibilidad. Muchas gracias, quedo a disposición para responder sus preguntas."